Predicción de la duración de viajes de taxi en Nueva York

Desde la limpieza hasta Fourier, wavelets Haar y ensambles

Christian Gabriel Villafuerte Aguilar

Sistemas Inteligentes · MAC · FES Acatlán, UNAM

Octubre de 2026

Ruta de la exposición

1. Qué se quiere predecir y cuál es la métrica oficial.
2. Auditoría de datos, limpieza y partición correcta.
3. Construcción de **81 variables** e imputación/escalado.
4. Comparación y ajuste de modelos de regresión.
5. Evaluación y optimización geográfica, Fourier y wavelets Haar.
6. Ensamble, holdout y entrega del CSV.

¿Por qué se hizo así?

El objetivo no es mostrar solamente un puntaje: se debe justificar un proceso reproducible y evitar fuga de información.

¿Cuál es el problema?

- Entrada: datos de cada viaje de taxi amarillo.
- Salida deseada: `trip_duration`, en **segundos**.
- Entrenamiento: **700,000** viajes con duración conocida.
- Evaluación ciega: **100,000** viajes sin duración.
- Entrega: un valor no negativo por cada `id`.

Tipo de aprendizaje

Supervisado

Tipo de tarea

Regresión

¿Por qué se hizo así?

La duración puede tomar muchos valores numéricos; no estamos decidiendo una clase "corto/largo". Por eso no corresponde usar un clasificador.

¿Por qué RMSLE y no accuracy o F1?

Métrica oficial: Root Mean Squared Logarithmic Error

$$\text{RMSLE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\Big[\ln(1+\widehat{y}_i) - \ln(1+y_i)\Big]^2}.$$

En regresión: RMSLE, MAE, RMSE, R^2, MAPE.

En clasificación: accuracy, precision, recall, F1.

- **Menor RMSLE significa mejor resultado.**
- La escala logarítmica da relevancia a los errores relativos.

¿Por qué se hizo así?

Crear clases artificiales para calcular F1 cambiaría el problema y no optimizaría la evaluación del concurso.

Metodología de clase: ciclo de vida CRISP-DM



Aplicación concreta en el notebook

CSV → auditoría → partición → 81 atributos → modelos → holdout → `submission.csv`.

¿Por qué se hizo así?

Es el enfoque explicado en la presentación *Ciclo de vida del ML*: antes del algoritmo van la calidad de datos y el planteamiento de la métrica.

¿Qué información contienen los archivos?

Campo	Interpretación y uso
`id`	Identificador: se conserva para entregar, no se entrena con él.
`vendor_id`	Empresa: se mantiene como variable numérica/código.
`pickup_datetime`	Fecha y hora de inicio: genera variables temporales.
`passenger_count`	Número declarado de pasajeros: contiene alguna anomalía.
`pickup_*`, `dropoff_*`	Coordenadas de origen/destino: permiten calcular distancias.
`store_and_fwd_flag`	Conexión interrumpida (Y/N): se codifica 1/0.
`trip_duration`	Variable objetivo, solo en `train.csv`.

¿Por qué se hizo así?

No se usa `id` como predictor porque es una etiqueta administrativa sin una relación física justificada con la duración.

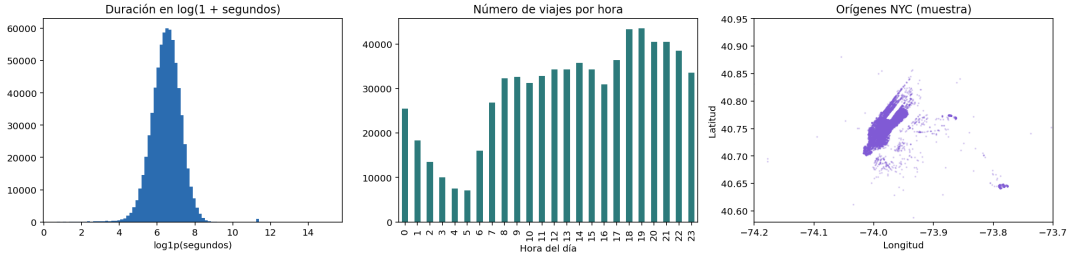
Auditoría inicial: ¿los CSV están limpios?

- **0** valores nulos originales en `train` y `test`.
- **0** IDs duplicados en ambos archivos.
- **0** duraciones menores o iguales a cero.
- **24** registros con cero pasajeros.
- **984** duraciones mayores que 12 horas.
- **2** duraciones mayores que 24 horas.
- **32** orígenes fuera de caja GPS NYC.
- **54** destinos fuera de esa caja.

¿Por qué se hizo así?

Que no haya nulos no significa que todos los registros sean plausibles. También se revisan consistencia temporal, GPS y valores extremos.

Exploración de datos: antes de modelar



Distribución logarítmica de duración, número de viajes por hora y ubicaciones de origen.

¿Por qué se hizo así?

La duración tiene una cola larga; una gráfica en segundos ocultaría gran parte de los viajes usuales. Las horas y ubicaciones justifican crear variables de contexto.

Decisiones explícitas sobre anomalías

Caso	Acción aplicada	Motivo
Viaje de más de 12 h	Se excluye **solo del ajuste**; no de validación ni holdout.	Reducir influencia de etiquetas extremas sin maquillar la evaluación.
GPS fuera de zona	Se marca con indicador y se convierte su coordenada a NaN.	No calcular distancias absurdas.
Cero pasajeros	Se marca con bandera de calidad; se conserva el dato.	Señal de calidad sin borrar el viaje.
`test.csv`	**Nunca** se eliminan filas.	Deben existir 100,000 predicciones.

¿Por qué se hizo así?

El umbral de 12 horas es una decisión heurística del experimento; conviene validarlo en estudios posteriores, no afirmar que es una regla universal.

División correcta: entrenamiento, validación y holdout

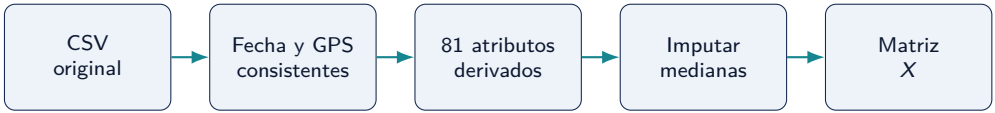


- En los 560,000 de la partición de entrenamiento se filtraron 788 viajes > 12 h: **559,212 usados para ajustar**.
- Validación: compara modelos y parámetros.
- Holdout: se consulta una vez, tras la selección.

¿Por qué se hizo así?

Si el holdout participa en el ajuste, deja de ser una evaluación independiente. Semilla fija: `random_state=42`.

Del dato crudo a una matriz numérica



Propiedad importante

La función `create_features` usa únicamente datos disponibles en los archivos de origen, **nunca la duración real** para construir predictores.

¿Por qué se hizo así?

El modelo no comprende de forma automática que dos coordenadas implican una distancia o que las 23:00 y las 00:00 están muy próximas.

Las 81 características: ¿de dónde salen?

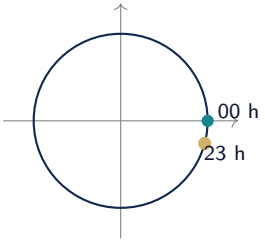
Grupo	Ejemplos implementados	Qué aportan
Tiempo	Hora, minuto, día, fin de semana, hora pico, seno/coseno	Congestión y periodicidad
Geometría	Haversine, Manhattan aprox., Δx, Δy, rumbo	Longitud y dirección
Zonas	Rejillas GPS, puntos medios	Barrios y trayectos frecuentes
Referencias	Distancia a JFK, LGA, EWR, Times Square y otros	Contexto urbano
Interacciones	Hora $\times$ distancia, hora pico $\times$ distancia	Relaciones no lineales
Calidad	GPS inválido, pasajero inválido, conexión diferida	Anomalías del registro

¿Por qué se hizo así?

Estas 81 columnas resultan de combinar conocimiento del dominio con transformaciones reproducibles; su cantidad no garantiza por sí sola calidad.

Variables temporales: ¿por qué usar seno y coseno?

$$h_{\sin} = \sin\left(\frac{2\pi h}{24}\right), \qquad h_{\cos} = \cos\left(\frac{2\pi h}{24}\right).$$



- 23:00 y 00:00 son horas contiguas.
- Una hora numérica normal no refleja bien esa cercanía.
- También se aplican ciclos a días y meses.

¿Por qué se hizo así?

La codificación cíclica hace que el cambio de día no aparezca como un salto artificial de 23 a 0.

¿Cómo calcular la distancia entre dos coordenadas?

Fórmula de Haversine (distancia sobre la esfera terrestre)

$$a = \sin^2\left(\frac{\Delta\varphi}{2}\right) + \cos\varphi_1 \cos\varphi_2 \sin^2\left(\frac{\Delta\lambda}{2}\right),$$
$$d = 2R \arcsin(\sqrt{a}), \qquad R \simeq 6371\,\mathrm{km}.$$

- φ: latitud; λ: longitud, en radianes.
- La distancia Haversine estima el trayecto directo, **no** las calles recorridas.
- Se añade distancia Manhattan aproximada para representar desplazamientos ortogonales.

¿Por qué se hizo así?

Las coordenadas originales son difíciles de interpretar solas; las distancias aportan una relación más directa con el tiempo esperado.

Geografía urbana y relaciones entre variables

Origen / destino

- Distancia a JFK, LaGuardia y Newark.
- Distancia a Times Square, Grand Central y Downtown.
- Celdas y punto medio de la trayectoria.

Combinaciones

- `hour_x_distance`.
- `rush_x_distance`.
- Ángulo del trayecto y sus seno/coseno.
- Distancias al cuadrado y logarítmicas.

¿Por qué se hizo así?

Un trayecto de 5 km durante hora pico puede durar distinto que el mismo trayecto por la madrugada; la interacción captura esa dependencia.

Imputación: ¿qué hacer cuando una coordenada es inválida?

1. Detectar coordenadas fuera de una caja geográfica razonable.
2. Crear bandera de calidad y sustituir la coordenada inválida por `NaN`.
3. Aprender la **mediana de cada característica** usando **únicamente entrenamiento**.
4. Aplicar las mismas medianas a validación, holdout y test.

Implementación real

```
SimpleImputer(strategy='median', keep_empty_features=True)
```

¿Por qué se hizo así?

La mediana suele ser más resistente que la media a extremos. Si se calculase usando todo el conjunto, entrarían estadísticas de validación o prueba en el entrenamiento.

Normalización, escalado y logaritmo: NO son lo mismo

Técnica	**Expresión**	**¿Se usó?**
Estandarización	$(x - \mu)/\sigma$	Se explica, pero no se aplicó a los árboles.
Min–max	$(x - x_{\text{mín}})/(x_{\text{máx}} - x_{\text{mín}})$	No se aplicó.
Escalado robusto	$(x - \text{mediana})/\text{IQR}$	**Sí: solo en Ridge**.
Transformación del objetivo	$z = \ln(1 + y)$	**Sí: en todos los modelos**.

¿Por qué se hizo así?

Ridge penaliza coeficientes y necesita escalas comparables; los árboles separan por umbrales, así que no requieren escalado para funcionar.

Transformación de la duración para entrenar

Objetivo de entrenamiento

$$z = \ln(1 + \texttt{trip_duration}).$$

Recuperar segundos

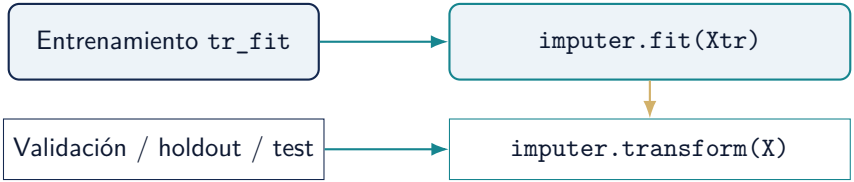
$$\widehat{y} = \max\{0, \exp(\widehat{z}) - 1\}.$$

- Reduce la asimetría de la duración.
- Es consistente con la métrica RMSLE.
- Evita valores negativos en el archivo final.
- **No** significa que se entregue el logaritmo.

¿Por qué se hizo así?

Se optimiza en la escala logarítmica y después se regresa a segundos, que es la unidad requerida por el reto.

¿Cómo se evitó la fuga de información?



- No se ajustan medianas ni `RobustScaler` con validación o test.
- No se calcula velocidad usando duración real ni se inventa hora de llegada.
- La evaluación holdout ocurre después de seleccionar el ganador.

¿Por qué se hizo así?

Una métrica artificialmente baja por fuga de información no mide la capacidad real de generalizar.

Primero: dos referencias fáciles de explicar

Modelo ingenuo: mediana

Predice para todos los viajes la mediana de la duración en escala logarítmica.

RMSLE = 0.795413

Ridge: regresión lineal

Modelo lineal con regularización L_2 y `RobustScaler`. **RMSLE = 0.462847**

¿Por qué se hizo así?

El baseline fija el mínimo que debemos superar; Ridge evalúa cuánto se puede explicar con una relación lineal regularizada.

¿Por qué Ridge en vez de quedarse con regresión lineal?

Idea matemática

$$\widehat{\beta} = \arg\min_{\beta} \left\{ \sum_{i=1}^{n} (z_i - \beta_0 - \mathbf{x}_i^\top \beta)^2 + \alpha \|\beta\|_2^2 \right\}, \qquad \alpha = 100.$$

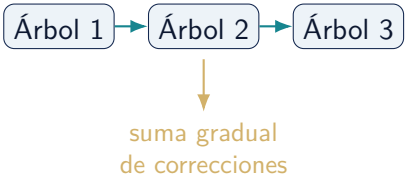
- La penalización reduce coeficientes excesivamente grandes.
- Es útil con muchas variables correlacionadas.
- Se ajusta sobre atributos escalados de forma robusta.
- Pero tiene dificultades con interacciones no lineales complejas.

¿Por qué se hizo así?

Ridge es una referencia interpretable y regularizada, no necesariamente el modelo final.

¿Por qué pasar a árboles de boosting?

- Distancia y duración no mantienen siempre relación lineal.
- Influyen hora, zona, aeropuerto y trayecto simultáneamente.
- **Boosting** añade árboles que corrigen errores anteriores.
- Puede capturar interacciones y cortes no lineales.



¿Por qué se hizo así?

Los métodos de árboles trabajan con umbrales; por ello aquí no añadimos escalado de entrada que no aporta una ventaja clara.

Modelos probados y motivo de comparación

Modelo	Idea	Motivo del ensayo
LightGBM	Boosting eficiente con árboles orientados a hojas.	Eficiencia en datos tabulares grandes.
XGBoost	Boosting regularizado con árboles.	Comparación con otra implementación sólida.
CatBoost	Boosting con mecanismos de regularización propios.	Contrastar estabilidad y desempeño.
Blends	Combinaciones ponderadas en escala log.	Comprobar si se complementan sus errores.

¿Por qué se hizo así?

No se declaró ganador por popularidad: todos se compararon con el mismo conjunto de validación y la misma métrica.

¿Qué parámetros se ajustaron en LightGBM?

Hiperparámetro	Equilibrado	Profundo	Regularizado
`n_estimators`	1400	1600	1650
`learning_rate`	0.045	0.045	0.035
`num_leaves`	63	105	39
`min_child_samples`	45	75	75
`colsample_bytree`	0.87	0.92	0.83
`subsample`	0.87	0.90	0.88
`reg_lambda`	2.5	5	6
RMSLE de validación	**0.379249**	**0.375735**	**0.382771**

Criterio aplicado

Entrenamiento sobre $\ln(1+y)$; evaluación por RMSLE; *early stopping* con 90 rondas sin mejora para LightGBM.

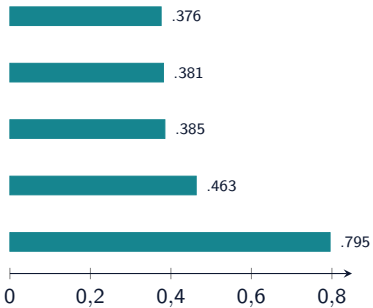
¿Por qué se hizo así?

Más hojas pueden capturar estructuras complejas, pero se controlan con mínimo de muestras por hoja y regularización. No se exploró todo el espacio de parámetros.

Resultados de validación: comparación objetiva

Modelo	RMSLE ↓
LightGBM profundo	**0.375735**
LightGBM equilibrado	0.379249
XGBoost	0.381371
LightGBM regularizado	0.382771
CatBoost	0.385040
Ridge escalado	0.462847
Mediana	0.795413

Ganador entre los modelos ensayados: LightGBM profundo.



¿Por qué se hizo así?

El único criterio de selección fue minimizar RMSLE en la validación; valores menores indican mejores predicciones relativas.

¿Se intentó combinar modelos? Sí

Ensamble probado	**RMSLE**
75 % LightGBM profundo + 25 % LightGBM equilibrado	0.375912
50 % LightGBM profundo + 50 % LightGBM equilibrado	0.376559
25 % LightGBM profundo + 75 % LightGBM equilibrado	0.377673
50/30/20 (profundo / equilibrado / XGBoost)	0.376475
LightGBM profundo sin mezcla	**0.375735**

¿Por qué se hizo así?

Un ensamble no garantiza mejora. Como ninguno superó al modelo individual, el resultado final usa un solo LightGBM: mejor RMSLE y menor complejidad.

Primera evaluación: 70,000 viajes holdout

RMSLE en validación

0.375735

RMSLE en holdout

0.381219

Métrica complementaria en holdout	Valor
MAE	270.92 segundos
RMSE	3,062.55 segundos
R^2	0.0390
MAPE	25.48 %

¿Por qué se hizo así?

El holdout se mantuvo ajeno a la selección, por lo que su RMSLE es una estimación más honesta de generalización; no es el puntaje de test ciego.

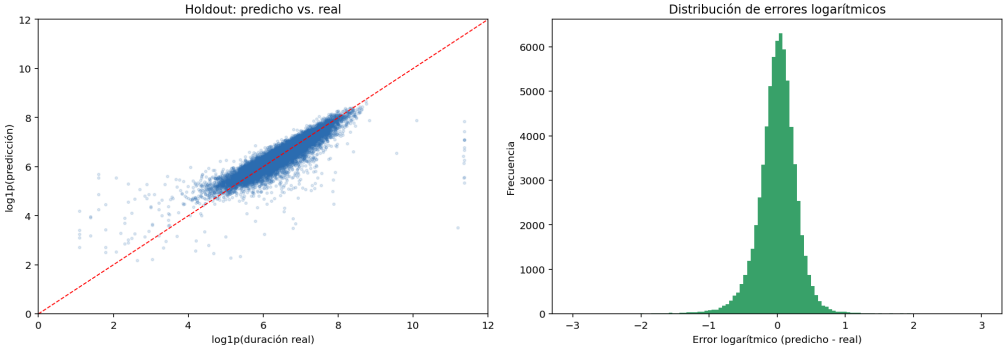
Interpretación: RMSLE vs. MAE, RMSE y R^2

Métrica	Qué nos dice
RMSLE	Penaliza errores al comparar **log-duraciones**; es la métrica oficial.
MAE	En promedio hay **270.92 s** de error absoluto en holdout (unos 4.5 min).
RMSE	**3,062.55 s**; muy sensible a errores grandes en segundos.
R^2	**0.039**: el ajuste en escala de segundos explica poca varianza de estas etiquetas.
MAPE	**25.48 %**, pero puede ser inestable cuando la duración real es pequeña.

¿Por qué se hizo así?

El mismo modelo puede rendir bien en RMSLE y mal en RMSE/R^2: no son métricas intercambiables y los valores extremos influyen mucho en segundos.

Diagnóstico: ¿en qué casos se equivoca?

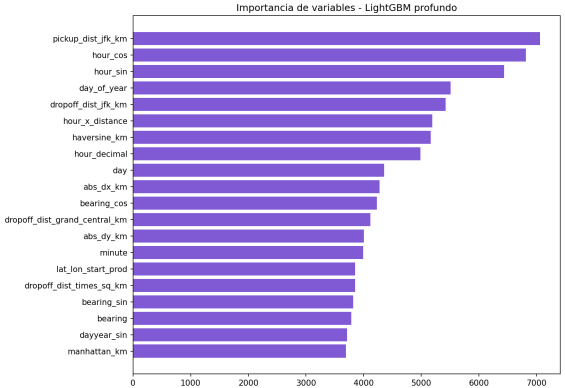


Predicción frente a valor real en logaritmos; distribución del error logarítmico.

¿Por qué se hizo así?

Las dispersiones y sesgos ayudan a detectar sobreestimación, subestimación y viajes atípicos. Una sola métrica agregada no explica todos los fallos.

Importancia de variables según LightGBM



- Distancia a **JFK** desde el origen.
- Componentes cíclicas de la **hora**.
- **Día del año**.
- Distancia a JFK desde destino.
- **Hora** $\times$ **distancia**.
- **Distancia Haversine**.

¿Por qué se hizo así?

Es una importancia interna del árbol (cantidad de uso de variables en cortes), no demuestra causalidad ni ordena necesariamente el efecto real de cada característica.

El error depende de la distancia del trayecto

Distancia Haversine	Viajes holdout	RMSLE
Menos de 0.5 km	2,504	1.103559
0.5 a 2 km	31,070	0.368468
2 a 5 km	23,896	0.290010
5 a 10 km	8,250	0.260631
10 a 25 km	4,200	0.275809
Más de 25 km	76	0.245508

rangos por GPS inválido.

Nota: cuatro viajes holdout no entran en estos

¿Por qué se hizo así?

En viajes muy cortos, paradas, espera y registros de GPS pueden dominar el tiempo; algunos grupos tienen pocas observaciones. Se trata de un diagnóstico, no de una prueba causal.

Segunda etapa: ¿por qué no bastaron las 81 variables?

- La distancia recta no describe el trazado urbano ni la congestión.
- Se probaron agrupaciones geográficas, ejes de Manhattan y estadísticas de trayectos.
- Algunas codificaciones de zonas empeoraron el RMSLE: eran demasiado específicas.
- Se conservaron variables geométricas continuas y estadísticas *out-of-fold* (OOF).

Criterio de decisión

Mejora en validación

NO complejidad por sí sola

Experimento previo

0.374624

RMSLE de validación

¿Por qué se hizo así?

Probamos hipótesis de dominio y retiramos características que agregaban sobreajuste. La evaluación usa siempre la misma partición.

Geografía urbana: ejes, regiones y trayectos

- Conversión aproximada de latitud/longitud a desplazamientos en kilómetros.
- Proyección rotada respecto de los ejes principales de Manhattan.
- Diferencias de coordenadas entre origen y destino.
- Clústeres y parejas origen–destino, pero con regularización/codificación OOF.

Ejemplo geométrico

$$\Delta x = 111{,}195 \cos(\bar{\varphi}) \Delta\lambda$$

$$\Delta y = 111{,}195 \Delta\varphi$$

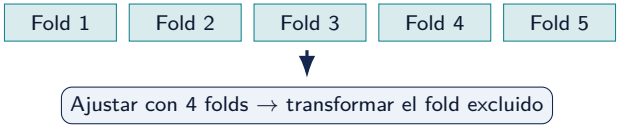
$$d_{\text{man}} \approx |\Delta x| + |\Delta y|$$

¿Por qué se hizo así?

La red vial hace que dos trayectos con similar Haversine puedan tener tiempos distintos. Las nuevas coordenadas no emplean el objetivo.

Codificación de promedios geográficos *out-of-fold*

Para usar tiempos históricos por zona, cada viaje debe recibir una estimación **sin su propia etiqueta**.



$$\widehat{\mu}_g = \frac{n_g \overline{z}_g + \alpha \overline{z}}{n_g + \alpha}, \qquad z = \log(1 + y),$$

- α suaviza categorías con muy pocos registros.
- Se repite el procedimiento para los cinco folds.
- Validación/test usan mapeos entrenados **solo** con train.

Resultados de la mejora geográfica

Configuración	Validación RMSLE	Holdout RMSLE
LightGBM inicial profundo	0.375735	0.381219
Ensamble geográfico + OOF	**0.374624**	**0.379288**

Lección

El avance existe, pero es modesto: aún hay estructura temporal y variaciones locales que las coordenadas por sí solas no explican.

¿Por qué se hizo así?

Por eso probamos análisis espectral y multirresolución como una *nueva hipótesis* y no como una garantía de RMSLE 0.20.

¿Por qué Fourier para viajes de taxi?

- La demanda cambia con **horas pico, turnos, fines de semana** y estacionalidad.
- Una hora numérica no codifica automáticamente que las 23:59 y 00:01 están muy cerca.
- Fourier describe patrones periódicos mediante senos y cosenos a distintas frecuencias.

$$\phi_{k,\sin}(t) = \sin\left(\frac{2\pi k t}{T}\right), \quad \phi_{k,\cos}(t) = \cos\left(\frac{2\pi k t}{T}\right).$$

Periodos empleados

$T = 24$ horas, $T = 7$ días y una fase estacional sobre 366 días; k representa la armónica.

FFT: pasar de tiempo a frecuencia

Partimos de una señal de **conteos de inicios de viaje cada 30 minutos** creada con el subconjunto de entrenamiento.

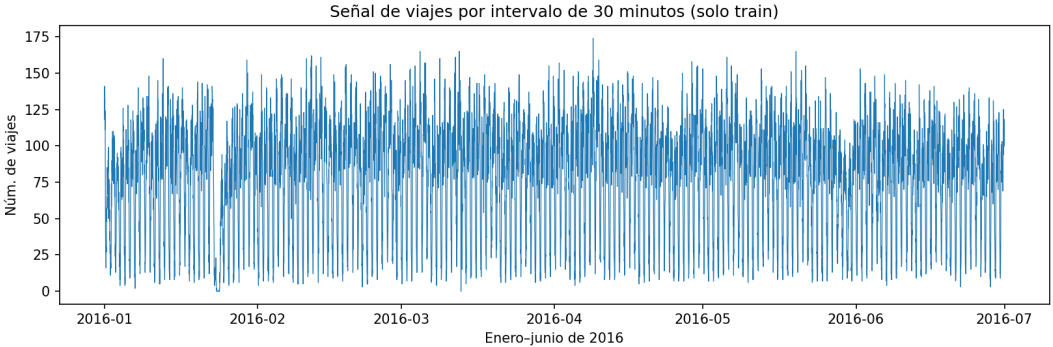
$$X_k = \sum_{n=0}^{N-1} x_n e^{-2\pi i k n / N}, \qquad k = 0, \ldots, N-1.$$

- x_n: número transformado de viajes en la franja n.
- $|X_k|^2$: energía/potencia asociada a la frecuencia k.
- FFT: algoritmo eficiente para calcular la transformada discreta.

¿Por qué se hizo así?

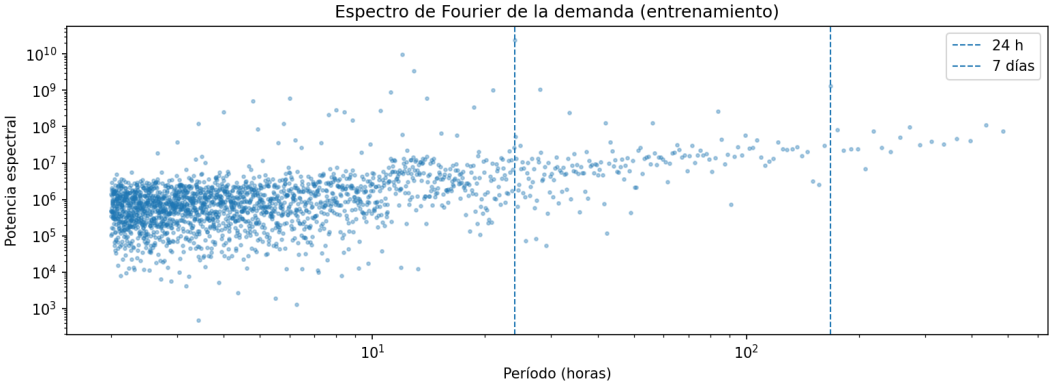
Se analiza la periodicidad *de los registros de entrenamiento*, sin recurrir a ninguna duración del test ciego.

Demanda temporal observada en entrenamiento



Conteos de pickups; las oscilaciones reflejan el ritmo de viajes, no una medición de tráfico real.

Espectro encontrado: ciclos de 24 h y 7 días



Se identificaron periodicidades relevantes, incluyendo componentes próximas a 12 h, 24 h y 168 h; **esto no prueba que mejoren por sí solas la predicción**.

45 bases deterministas: temporales y espaciales

Grupo	Qué se construyó
Fourier diario	Armónicas $k = 2, 3, 4, 6, 8, 12$: senos y cosenos
Fourier semanal	$k = 1, 2, 3, 4, 6, 8, 12$: senos y cosenos
Fourier estacional	Armónicas $k = 2, 3, 4$ del día del año
Fases Haar fijas	5 señales de cambio de signo por bloques
Fourier espacial	Cosenos de latitud/longitud de origen y destino a 2 y 6 km

Ninguna usa la duración

Estas 45 características dependen exclusivamente de `pickup_datetime` y de coordenadas disponibles en ambos CSV.

Filtrado espectral: tendencia y bandas

A partir de la serie de demanda, se conservan frecuencias bajas y se reconstruye por transformada inversa:

$$L_T(t) = \mathcal{F}^{-1}\big(\mathcal{F}(x)\,\mathbf{1}_{\{|f|\le 1/T\}}\big)(t), \qquad B_T = L_T - L_{T'},$$

- Ventanas representadas: **12, 48 y 168 horas**.
- El componente lento resume tendencias; la diferencia entre escalas aproxima una banda.
- Los filtros se aprenden de **conteos de train**; para aplicar a test se reutiliza esa señal.

¿Por qué se hizo así?

Los modelos basados en árboles pueden usar tanto armónicas explícitas como señales suavizadas sin que debamos estandarizarlas.

¿Qué agregan las wavelets que Fourier no explica?

Fourier

Describe patrones **globales** repetidos; una frecuencia aparece en toda la ventana analizada.

Haar

Describe **cambios locales** y diferencias entre resoluciones temporales.

- Un cambio abrupto de demanda puede quedar diluido en un promedio diario.
- Las aproximaciones muestran la actividad lenta y los detalles muestran transiciones.

¿Por qué se hizo así?

Son representaciones *complementarias*; ninguna genera información adicional sobre el tráfico que no está en los datos.

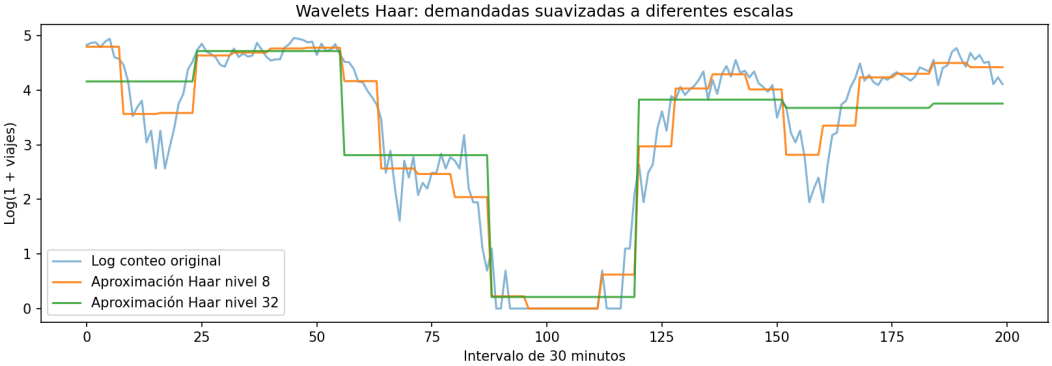
Wavelet Haar: aproximación y detalle

Para bloques diádicos de tamaño s, definimos la reconstrucción de la aproximación:

$$A_s(t) = \frac{1}{s} \sum_{j \in \text{bloque}_s(t)} x_j, \qquad D_s(t) = A_{s/2}(t) - A_s(t).$$

- A_s resume el promedio de demanda a escala s.
- D_s conserva el cambio que desaparece al aumentar la escala.
- Se implementó la reconstrucción Haar en **NumPy** (sin dependencia PyWavelets).
- Ejemplos: 2, 8 y 32 intervalos de 30 minutos equivalen a 1, 4 y 16 horas.

Haar multiescala sobre la demanda



Señal de entrenamiento: la aproximación conserva la estructura general; el detalle destaca fluctuaciones a distintas escalas.

27 características de demanda Fourier/Haar

Se construyeron señales con inicios de viajes de **solo entrenamiento**, por región aproximada:

- **3 regiones**: general, Manhattan y alrededores de aeropuertos.
- Por región: 6 aproximaciones/detalles Haar seleccionados y 3 componentes FFT.
- Total: $3 \times (6 + 3) = \boxed{27}$ variables.

Transformación estable

$$x_t = \log\left(1 + \text{conteos}_t \cdot 100000 / n_{\text{ref}}\right).$$

Los conteos se ajustan al tamaño del conjunto de referencia y se suavizan con $\log(1 + \cdot)$.

¿Por qué se hizo así?

La demanda se interpreta como una **señal proxy**, no como medición directa de velocidad ni de tráfico.

14 características espectrales basadas en duración

Para la media hora de la semana b, se estima la duración logarítmica típica, suavizada:

$$\widetilde{\mu}_b = \frac{\sum_{i \in b} \log(1 + y_i) + 45\overline{z}}{n_b + 45}.$$

- **5** reconstrucciones FFT conservando armónicas bajas.
- **8** aproximaciones/detalles Haar a 4 escalas.
- **1** media semanal suavizada.

Condición indispensable

Estas 14 variables **sí utilizan el objetivo**: deben generarse **out-of-fold** en train; para validación/test se ajustan solamente con el train permitido.

Prueba OOF: la fila no puede verse a sí misma

1. Separar train en **5 folds** (semilla 47).
2. Para el fold j, construir promedios y wavelets a partir de los **otros cuatro folds**.
3. Transformar únicamente los registros del fold j.
4. Concatenar los cinco resultados en el orden original.
5. Ajustar un codificador con **todo el train permitido** para transformar validación/test.

Prueba programática documentada

Al cambiar y_i de una observación, sus propias columnas supervisadas OOF **no se modifican**. Es una verificación parcial, no una garantía formal de ausencia de toda fuga.

Inventario preciso de características

Origen	Cantidad nueva	Acumulado
Originales y geográficas básicas	81	81
Fourier/Haar deterministas	45	126
Demanda regional en varias escalas	27	153
Estadísticas espectrales de duración OOF	14	**167**

Tres configuraciones efectivamente entrenadas

126 (bases fijas) $\longrightarrow$ **153** (+demanda) $\longrightarrow$ **167** (+OOF).

¿Por qué se hizo así?

Esta comparación por etapas permite saber *qué familia de variables aporta información* y cuál podría generar ruido.

Modelo espectral: ¿por qué LightGBM?

- Aprende interacciones no lineales entre **distancia, hora, origen, destino y periodicidad**.
- Tolera bien relaciones con umbrales y escalas diferentes, sin `StandardScaler` obligatorio.
- Permite regularización y control de complejidad con muchos registros.
- El modelo se entrena con $z = \log(1 + \texttt{trip_duration})$.

Configuración comparable

`n_estimators=1700; learning_rate=0.045; num_leaves=105;`
`min_child_samples=75; reg_lambda=5; colsample=0.92;`
`subsample=0.90; seed=42; early_stopping=110` en validación.

Ablación: no todas las wavelets mejoran

Modelo individual	Variables	RMSLE val.
Referencia original	81	0.375798
Fourier/Haar fijas	126	0.376372
Fourier + demanda Haar	153	0.376802
Fourier + demanda + target OOF	167	0.376833

Interpretación

Las variantes espectrales **solas** fueron peores que la referencia en esta partición. Sin embargo, pueden cometer errores distintos y resultar útiles en combinación.

¿Por qué se hizo así?

No se seleccionó el modelo espectral individual como ganador por tener más variables.

¿Por qué probar un ensamble y en qué escala?

Dos modelos complementarios pueden compensar errores. La combinación se hace **en log-duración**, la escala alineada con RMSLE:

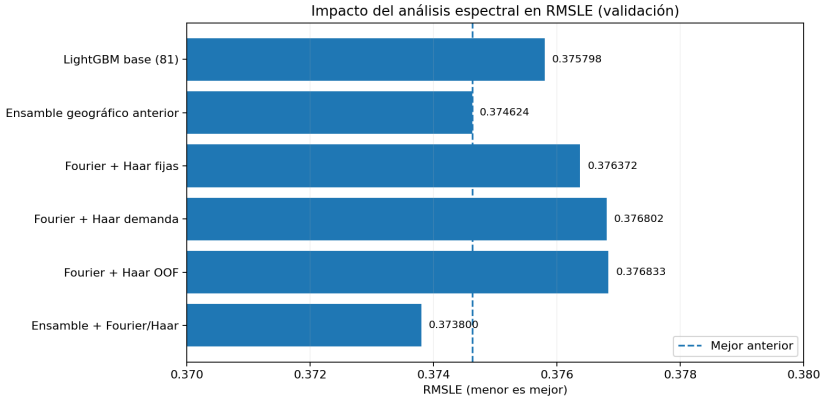
$$\widehat{z} = w\,\widehat{z}_{\text{geo}} + (1-w)\widehat{z}_{\text{espectral}}, \qquad \widehat{y} = \max\left(0, e^{\widehat{z}} - 1\right).$$

- Se compararon los pesos w en **validación**.
- Se conservaron las predicciones del mejor ensamble geográfico anterior.
- Se evaluaron las 3 variantes espectrales y sus combinaciones.

Regla

Nunca ajustar los pesos usando holdout ni `test.csv`.

Comparación final en validación



Menor es mejor. Se mantuvieron las variantes que empeoraron para documentar el proceso de selección.

Ganador: 75 % previo + 25 % espectral

- **75 %**: ensamble geográfico anterior, entrenado sin fuga.
- **25 %**: LightGBM de 167 variables con Fourier + Haar + target OOF.
- Pesos elegidos **solo por validación**.
- Predicciones combinadas en escala $\log(1 + y)$.

Resultado de validación

0.373800

RMSLE

Previo

0.374624
RMSLE

¿Por qué se hizo así?

La reducción fue de aproximadamente 0,000824 RMSLE en validación; es pequeña pero observable.

Prueba sellada: resultados de holdout

Evaluación	Geográfico previo	Fourier + Haar
Validación (70,000)	0.374624	**0.373800**
Holdout (70,000)	0.379288	**0.378590**

Disciplina de evaluación

- La elección del peso se hizo antes de consultar el holdout.
- El conjunto ciego de 100,000 viajes **nunca** aporta etiquetas.
- El puntaje externo de **0.3704** fue reportado por el usuario para otro envío y **no es comparable directamente** con estos valores locales.

Diagnóstico: los viajes extremos dominan parte del error

Duración real (validación)	Casos	Porción del error log-cuadrático
1 a 60 s	433	10.21 %
61 a 300 s	10,149	14.04 %
301 a 900 s	35,997	26.33 %
901 a 3,600 s	22,827	22.63 %
3,601 a 43,200 s	491	2.38 %
Mayor de 12 h	**103**	**24.41 %**

¿Por qué se hizo así?

No se eliminaron extremos de validación: hacerlo produciría una estimación artificialmente favorable. Estos 103 casos son un diagnóstico, no un límite teórico para RMSLE.

Limitación metodológica: evaluación temporal

Qué sí garantiza el experimento local

- No se usan etiquetas del `test.csv`.
- La mediana y las señales supervisadas se ajustan solo con train.
- OOF impide incorporar la propia etiqueta en los predictores de esa fila.

Qué *no* garantiza

La partición aleatoria puede incorporar información de etiquetas de **fechas futuras** dentro del entrenamiento de otra fecha. Para pronosticar viajes futuros en producción se requerirían validación cronológica y agregaciones estrictamente causales.

Entrenamiento definitivo después de seleccionar

1. Tomar **700,000** filas etiquetadas y filtrar **solo en el ajuste** duraciones fuera de $[1, 43200]$ s.
2. Quedan **699,016** filas para reajustar el componente final.
3. Reconstruir OOF, ajustar medianas **solo sobre entrenamiento** y entrenar el LightGBM de **167 variables**.
4. Combinar 75/25 con el modelo geográfico anterior, ya reentrenado.
5. Predecir cada registro de `test.csv` y transformar con $\exp(z) - 1$, recortando a cero.

Sin contaminación del test

La predicción no contiene ninguna medición de `trip_duration` del conjunto ciego: no existe en `test.csv`.

Verificación del CSV entregable

Formato requerido, **sin columnas auxiliares**:

```
submission = pd.DataFrame({
    'id': test['id'], 'trip_duration': pred
})
assert submission.columns.tolist() == ['id','trip_duration']
assert len(submission) == 100_000
assert submission['id'].is_unique
assert submission['id'].equals(test['id'])
assert np.isfinite(submission['trip_duration']).all()
assert (submission['trip_duration'] >= 0).all()
submission.to_csv('submission_wavelet_fft.csv', index=False)
```

¿Por qué se hizo así?

La calidad de un modelo también depende de que el archivo final cumpla exactamente las condiciones técnicas de la evaluación.

Mapa de los archivos y reproducción

Archivo / módulo	Para qué sirve
Notebook principal (`.ipynb`)	Fases, fórmulas, gráficos y evaluación
`features_taxi.py`	Construye 81 variables base
`wavelet_fft_taxi.py`	Fourier, Haar y codificador OOF
Script de experimentos	Entrena tres variantes y guarda métricas
Script de ensambles	Selección exclusiva en validación
Script de holdout	Evaluación final reservada
Script de reentrenamiento	Crea el CSV con el modelo final
Script de predicción	Reproduce la entrega desde modelos guardados

Los nombres completos y el orden de ejecución están en `README_Wavelets_Fourier.md`.

Conclusiones: qué aprendimos del experimento

1. El reto es **regresión**: RMSLE es la medida objetivo, no F1 ni accuracy.
2. La ingeniería de características suele importar más que probar algoritmos al azar.
3. **Fourier** detectó ciclos temporales; **Haar** representó variaciones multiescala.
4. Las variantes espectrales **individuales** empeoraron; el **ensamble** mejoró ligeramente.
5. El mejor holdout pasó de **0.379288** a **0.378590**, con selección por validación.
6. El objetivo **0.20 no se consiguió**; la puntuación ciega del nuevo CSV aún debe medirse externamente.

Cómo defender el proyecto en preguntas

¿Por qué no F1? Porque la variable objetivo es continua, no una clase.

¿Por qué logaritmo? Para alinear el entrenamiento con RMSLE y controlar errores multiplicativos.

¿Por qué LightGBM? Captura interacciones no lineales, escala a muchos viajes y no exige estandarización.

¿Por qué OOF? Para que los promedios de `trip_duration` no incluyan el objetivo de la fila que predicen.

¿Por qué mezclar? Los errores de un modelo geométrico y uno espectral pueden ser complementarios.

¿Llegamos a 0.20? No. Reportamos valores medidos y sus límites.

Referencias y material de apoyo

- **U5 – 01 – ML.pdf**, *Introducción al Machine Learning*: aprendizaje supervisado, regresión y función de costo.
- **U5 – 02 – Perceptrón.pdf**: descenso de gradiente y distinción entre activaciones de regresión/clasificación.
- **03 – Ciclo de vida del ML.pdf**: CRISP-DM, preprocesamiento, partición y prevención de *data leakage*.
- Scripts y notebook del proyecto, incluidos en este ZIP: evidencia de implementación y resultados, no resultados hipotéticos.

Gracias. ¿Preguntas?