Predicción de la duración de viajes de taxi en Nueva York

Del CSV a un modelo de regresión evaluado por RMSLE

Christian Gabriel Villafuerte Aguilar

Sistemas Inteligentes · MAC · FES Acatlán, UNAM

Octubre de 2026

Ruta de la exposición

1. Qué se quiere predecir y cuál es la métrica oficial.
2. Auditoría de datos, limpieza y partición correcta.
3. Construcción de **81 variables** e imputación/escalado.
4. Comparación y ajuste de modelos de regresión.
5. Evaluación independiente, interpretación y entrega del CSV.

¿Por qué se hizo así?

El objetivo no es mostrar solamente un puntaje: se debe justificar un proceso reproducible y evitar fuga de información.

¿Cuál es el problema?

- Entrada: datos de cada viaje de taxi amarillo.
- Salida deseada: `trip_duration`, en **segundos**.
- Entrenamiento: **700,000** viajes con duración conocida.
- Evaluación ciega: **100,000** viajes sin duración.
- Entrega: un valor no negativo por cada `id`.

Tipo de aprendizaje

Supervisado

Tipo de tarea

Regresión

¿Por qué se hizo así?

La duración puede tomar muchos valores numéricos; no estamos decidiendo una clase "corto/largo". Por eso no corresponde usar un clasificador.

¿Por qué RMSLE y no accuracy o F1?

Métrica oficial: Root Mean Squared Logarithmic Error

$$\text{RMSLE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\Big[\ln(1+\widehat{y}_i) - \ln(1+y_i)\Big]^2}.$$

En regresión: RMSLE, MAE, RMSE, R^2, MAPE.

En clasificación: accuracy, precision, recall, F1.

- **Menor RMSLE significa mejor resultado.**
- La escala logarítmica da relevancia a los errores relativos.

¿Por qué se hizo así?

Crear clases artificiales para calcular F1 cambiaría el problema y no optimizaría la evaluación del concurso.

Metodología de clase: ciclo de vida CRISP-DM



Aplicación concreta en el notebook

CSV → auditoría → partición → 81 atributos → modelos → holdout → `submission.csv`.

¿Por qué se hizo así?

Es el enfoque explicado en la presentación *Ciclo de vida del ML*: antes del algoritmo van la calidad de datos y el planteamiento de la métrica.

¿Qué información contienen los archivos?

Campo	Interpretación y uso
`id`	Identificador: se conserva para entregar, no se entrena con él.
`vendor_id`	Empresa: se mantiene como variable numérica/código.
`pickup_datetime`	Fecha y hora de inicio: genera variables temporales.
`passenger_count`	Número declarado de pasajeros: contiene alguna anomalía.
`pickup_*`, `dropoff_*`	Coordenadas de origen/destino: permiten calcular distancias.
`store_and_fwd_flag`	Conexión interrumpida (Y/N): se codifica 1/0.
`trip_duration`	Variable objetivo, solo en `train.csv`.

¿Por qué se hizo así?

No se usa `id` como predictor porque es una etiqueta administrativa sin una relación física justificada con la duración.

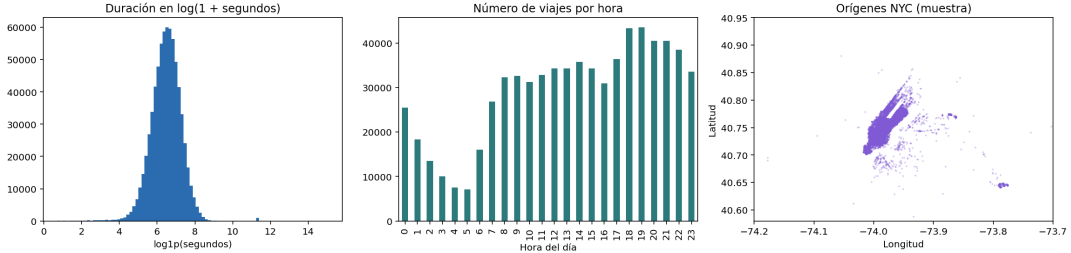
Auditoría inicial: ¿los CSV están limpios?

- **0** valores nulos originales en `train` y `test`.
- **0** IDs duplicados en ambos archivos.
- **0** duraciones menores o iguales a cero.
- **24** registros con cero pasajeros.
- **984** duraciones mayores que 12 horas.
- **2** duraciones mayores que 24 horas.
- **32** orígenes fuera de caja GPS NYC.
- **54** destinos fuera de esa caja.

¿Por qué se hizo así?

Que no haya nulos no significa que todos los registros sean plausibles. También se revisan consistencia temporal, GPS y valores extremos.

Exploración de datos: antes de modelar



Distribución logarítmica de duración, número de viajes por hora y ubicaciones de origen.

¿Por qué se hizo así?

La duración tiene una cola larga; una gráfica en segundos ocultaría gran parte de los viajes usuales. Las horas y ubicaciones justifican crear variables de contexto.

Decisiones explícitas sobre anomalías

Caso	Acción aplicada	Motivo
Viaje de más de 12 h	Se excluye **solo del ajuste**; no de validación ni holdout.	Reducir influencia de etiquetas extremas sin maquillar la evaluación.
GPS fuera de zona	Se marca con indicador y se convierte su coordenada a NaN.	No calcular distancias absurdas.
Cero pasajeros	Se marca con bandera de calidad; se conserva el dato.	Señal de calidad sin borrar el viaje.
`test.csv`	**Nunca** se eliminan filas.	Deben existir 100,000 predicciones.

¿Por qué se hizo así?

El umbral de 12 horas es una decisión heurística del experimento; conviene validarlo en estudios posteriores, no afirmar que es una regla universal.

División correcta: entrenamiento, validación y holdout

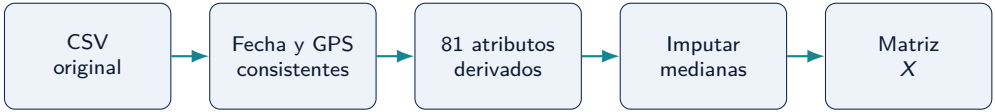


- En los 560,000 de la partición de entrenamiento se filtraron 788 viajes > 12 h: **559,212 usados para ajustar**.
- Validación: compara modelos y parámetros.
- Holdout: se consulta una vez, tras la selección.

¿Por qué se hizo así?

Si el holdout participa en el ajuste, deja de ser una evaluación independiente. Semilla fija: `random_state=42`.

Del dato crudo a una matriz numérica



Propiedad importante

La función `create_features` usa únicamente datos disponibles en los archivos de origen, **nunca la duración real** para construir predictores.

¿Por qué se hizo así?

El modelo no comprende de forma automática que dos coordenadas implican una distancia o que las 23:00 y las 00:00 están muy próximas.

Las 81 características: ¿de dónde salen?

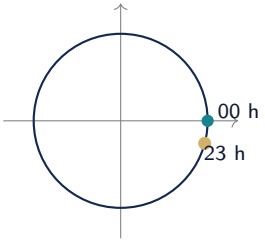
Grupo	Ejemplos implementados	Qué aportan
Tiempo	Hora, minuto, día, fin de semana, hora pico, seno/coseno	Congestión y periodicidad
Geometría	Haversine, Manhattan aprox., Δx, Δy, rumbo	Longitud y dirección
Zonas	Rejillas GPS, puntos medios	Barrios y trayectos frecuentes
Referencias	Distancia a JFK, LGA, EWR, Times Square y otros	Contexto urbano
Interacciones	Hora $\times$ distancia, hora pico $\times$ distancia	Relaciones no lineales
Calidad	GPS inválido, pasajero inválido, conexión diferida	Anomalías del registro

¿Por qué se hizo así?

Estas 81 columnas resultan de combinar conocimiento del dominio con transformaciones reproducibles; su cantidad no garantiza por sí sola calidad.

Variables temporales: ¿por qué usar seno y coseno?

$$h_{\sin} = \sin\left(\frac{2\pi h}{24}\right), \qquad h_{\cos} = \cos\left(\frac{2\pi h}{24}\right).$$



- 23:00 y 00:00 son horas contiguas.
- Una hora numérica normal no refleja bien esa cercanía.
- También se aplican ciclos a días y meses.

¿Por qué se hizo así?

La codificación cíclica hace que el cambio de día no aparezca como un salto artificial de 23 a 0.

¿Cómo calcular la distancia entre dos coordenadas?

Fórmula de Haversine (distancia sobre la esfera terrestre)

$$a = \sin^2\left(\frac{\Delta\varphi}{2}\right) + \cos\varphi_1 \cos\varphi_2 \sin^2\left(\frac{\Delta\lambda}{2}\right),$$
$$d = 2R \arcsin(\sqrt{a}), \qquad R \simeq 6371\,\mathrm{km}.$$

- φ: latitud; λ: longitud, en radianes.
- La distancia Haversine estima el trayecto directo, **no** las calles recorridas.
- Se añade distancia Manhattan aproximada para representar desplazamientos ortogonales.

¿Por qué se hizo así?

Las coordenadas originales son difíciles de interpretar solas; las distancias aportan una relación más directa con el tiempo esperado.

Geografía urbana y relaciones entre variables

Origen / destino

- Distancia a JFK, LaGuardia y Newark.
- Distancia a Times Square, Grand Central y Downtown.
- Celdas y punto medio de la trayectoria.

Combinaciones

- `hour_x_distance`.
- `rush_x_distance`.
- Ángulo del trayecto y sus seno/coseno.
- Distancias al cuadrado y logarítmicas.

¿Por qué se hizo así?

Un trayecto de 5 km durante hora pico puede durar distinto que el mismo trayecto por la madrugada; la interacción captura esa dependencia.

Imputación: ¿qué hacer cuando una coordenada es inválida?

1. Detectar coordenadas fuera de una caja geográfica razonable.
2. Crear bandera de calidad y sustituir la coordenada inválida por `NaN`.
3. Aprender la **mediana de cada característica** usando **únicamente entrenamiento**.
4. Aplicar las mismas medianas a validación, holdout y test.

Implementación real

```
SimpleImputer(strategy='median', keep_empty_features=True)
```

¿Por qué se hizo así?

La mediana suele ser más resistente que la media a extremos. Si se calculase usando todo el conjunto, entrarían estadísticas de validación o prueba en el entrenamiento.

Normalización, escalado y logaritmo: NO son lo mismo

Técnica	**Expresión**	**¿Se usó?**
Estandarización	$(x - \mu)/\sigma$	Se explica, pero no se aplicó a los árboles.
Min–max	$(x - x_{\text{mín}})/(x_{\text{máx}} - x_{\text{mín}})$	No se aplicó.
Escalado robusto	$(x - \text{mediana})/\text{IQR}$	**Sí: solo en Ridge**.
Transformación del objetivo	$z = \ln(1 + y)$	**Sí: en todos los modelos**.

¿Por qué se hizo así?

Ridge penaliza coeficientes y necesita escalas comparables; los árboles separan por umbrales, así que no requieren escalado para funcionar.

Transformación de la duración para entrenar

Objetivo de entrenamiento

$$z = \ln(1 + \texttt{trip_duration}).$$

Recuperar segundos

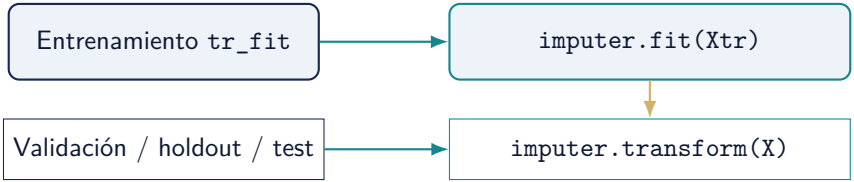
$$\widehat{y} = \max\{0, \exp(\widehat{z}) - 1\}.$$

- Reduce la asimetría de la duración.
- Es consistente con la métrica RMSLE.
- Evita valores negativos en el archivo final.
- **No** significa que se entregue el logaritmo.

¿Por qué se hizo así?

Se optimiza en la escala logarítmica y después se regresa a segundos, que es la unidad requerida por el reto.

¿Cómo se evitó la fuga de información?



- No se ajustan medianas ni `RobustScaler` con validación o test.
- No se calcula velocidad usando duración real ni se inventa hora de llegada.
- La evaluación holdout ocurre después de seleccionar el ganador.

¿Por qué se hizo así?

Una métrica artificialmente baja por fuga de información no mide la capacidad real de generalizar.

Primero: dos referencias fáciles de explicar

Modelo ingenuo: mediana

Predice para todos los viajes la mediana de la duración en escala logarítmica.

RMSLE = 0.795413

Ridge: regresión lineal

Modelo lineal con regularización L_2 y `RobustScaler`. **RMSLE = 0.462847**

¿Por qué se hizo así?

El baseline fija el mínimo que debemos superar; Ridge evalúa cuánto se puede explicar con una relación lineal regularizada.

¿Por qué Ridge en vez de quedarse con regresión lineal?

Idea matemática

$$\widehat{\beta} = \arg\min_{\beta} \left\{ \sum_{i=1}^{n} (z_i - \beta_0 - \mathbf{x}_i^\top \beta)^2 + \alpha \|\beta\|_2^2 \right\}, \qquad \alpha = 100.$$

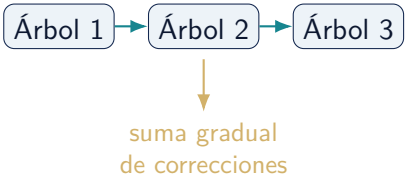
- La penalización reduce coeficientes excesivamente grandes.
- Es útil con muchas variables correlacionadas.
- Se ajusta sobre atributos escalados de forma robusta.
- Pero tiene dificultades con interacciones no lineales complejas.

¿Por qué se hizo así?

Ridge es una referencia interpretable y regularizada, no necesariamente el modelo final.

¿Por qué pasar a árboles de boosting?

- Distancia y duración no mantienen siempre relación lineal.
- Influyen hora, zona, aeropuerto y trayecto simultáneamente.
- **Boosting** añade árboles que corrigen errores anteriores.
- Puede capturar interacciones y cortes no lineales.



¿Por qué se hizo así?

Los métodos de árboles trabajan con umbrales; por ello aquí no añadimos escalado de entrada que no aporta una ventaja clara.

Modelos probados y motivo de comparación

Modelo	Idea	Motivo del ensayo
LightGBM	Boosting eficiente con árboles orientados a hojas.	Eficiencia en datos tabulares grandes.
XGBoost	Boosting regularizado con árboles.	Comparación con otra implementación sólida.
CatBoost	Boosting con mecanismos de regularización propios.	Contrastar estabilidad y desempeño.
Blends	Combinaciones ponderadas en escala log.	Comprobar si se complementan sus errores.

¿Por qué se hizo así?

No se declaró ganador por popularidad: todos se compararon con el mismo conjunto de validación y la misma métrica.

¿Qué parámetros se ajustaron en LightGBM?

Hiperparámetro	Equilibrado	Profundo	Regularizado
`n_estimators`	1400	1600	1650
`learning_rate`	0.045	0.045	0.035
`num_leaves`	63	105	39
`min_child_samples`	45	75	75
`colsample_bytree`	0.87	0.92	0.83
`subsample`	0.87	0.90	0.88
`reg_lambda`	2.5	5	6
RMSLE de validación	**0.379249**	**0.375735**	**0.382771**

Criterio aplicado

Entrenamiento sobre $\ln(1 + y)$; evaluación por RMSLE; *early stopping* con 90 rondas sin mejora para LightGBM.

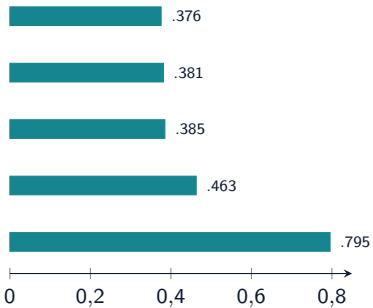
¿Por qué se hizo así?

Más hojas pueden capturar estructuras complejas, pero se controlan con mínimo de muestras por hoja y regularización. No se exploró todo el espacio de parámetros.

Resultados de validación: comparación objetiva

Modelo	RMSLE ↓
LightGBM profundo	**0.375735**
LightGBM equilibrado	0.379249
XGBoost	0.381371
LightGBM regularizado	0.382771
CatBoost	0.385040
Ridge escalado	0.462847
Mediana	0.795413

Ganador entre los modelos ensayados: LightGBM profundo.



¿Por qué se hizo así?

El único criterio de selección fue minimizar RMSLE en la validación; valores menores indican mejores predicciones relativas.

¿Se intentó combinar modelos? Sí

Ensamble probado	**RMSLE**
75 % LightGBM profundo + 25 % LightGBM equilibrado	0.375912
50 % LightGBM profundo + 50 % LightGBM equilibrado	0.376559
25 % LightGBM profundo + 75 % LightGBM equilibrado	0.377673
50/30/20 (profundo / equilibrado / XGBoost)	0.376475
LightGBM profundo sin mezcla	**0.375735**

¿Por qué se hizo así?

Un ensamble no garantiza mejora. Como ninguno superó al modelo individual, el resultado final usa un solo LightGBM: mejor RMSLE y menor complejidad.

Evaluación independiente: 70,000 viajes holdout

RMSLE en validación

0.375735

RMSLE en holdout

0.381219

Métrica complementaria en holdout	Valor
MAE	270.92 segundos
RMSE	3,062.55 segundos
R^2	0.0390
MAPE	25.48 %

¿Por qué se hizo así?

El holdout se mantuvo ajeno a la selección, por lo que su RMSLE es una estimación más honesta de generalización; no es el puntaje de test ciego.

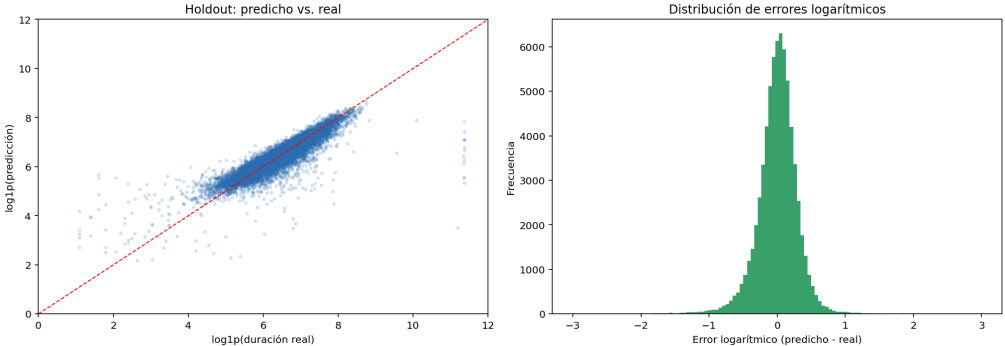
Interpretación: RMSLE vs. MAE, RMSE y R^2

Métrica	Qué nos dice
RMSLE	Penaliza errores al comparar **log-duraciones**; es la métrica oficial.
MAE	En promedio hay **270.92 s** de error absoluto en holdout (unos 4.5 min).
RMSE	**3,062.55 s**; muy sensible a errores grandes en segundos.
R^2	**0.039**: el ajuste en escala de segundos explica poca varianza de estas etiquetas.
MAPE	**25.48 %**, pero puede ser inestable cuando la duración real es pequeña.

¿Por qué se hizo así?

El mismo modelo puede rendir bien en RMSLE y mal en RMSE/R^2: no son métricas intercambiables y los valores extremos influyen mucho en segundos.

Diagnóstico: ¿en qué casos se equivoca?

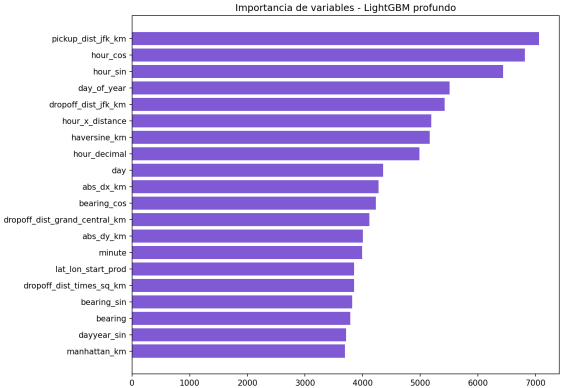


Predicción frente a valor real en logaritmos; distribución del error logarítmico.

¿Por qué se hizo así?

Las dispersiones y sesgos ayudan a detectar sobreestimación, subestimación y viajes atípicos. Una sola métrica agregada no explica todos los fallos.

Importancia de variables según LightGBM



- Distancia a **JFK** desde el origen.
- Componentes cíclicas de la **hora**.
- **Día del año**.
- Distancia a JFK desde destino.
- **Hora** $\times$ **distancia**.
- **Distancia Haversine**.

¿Por qué se hizo así?

Es una importancia interna del árbol (cantidad de uso de variables en cortes), no demuestra causalidad ni ordena necesariamente el efecto real de cada característica.

El error depende de la distancia del trayecto

Distancia Haversine	Viajes holdout	RMSLE
Menos de 0.5 km	2,504	1.103559
0.5 a 2 km	31,070	0.368468
2 a 5 km	23,896	0.290010
5 a 10 km	8,250	0.260631
10 a 25 km	4,200	0.275809
Más de 25 km	76	0.245508

rangos por GPS inválido.

Nota: cuatro viajes holdout no entran en estos

¿Por qué se hizo así?

En viajes muy cortos, paradas, espera y registros de GPS pueden dominar el tiempo; algunos grupos tienen pocas observaciones. Se trata de un diagnóstico, no de una prueba causal.

Entrenamiento final, ahora sí con todos los datos utilizables

1. Se seleccionó LightGBM profundo usando **solo validación**.
2. Se verificó su desempeño en **holdout**.
3. Se volvió a entrenar con **699,016 viajes etiquetados**, aplicando el filtro $1 \leq y \leq 43,200$ s.
4. Se calcularon de nuevo medianas con ese entrenamiento completo.
5. Se guardó el modelo: `modelos/modelo_final.joblib`.

¿Por qué se hizo así?

Después de cerrar la evaluación, tiene sentido aprovechar más ejemplos etiquetados. El modelo final ya no tiene un holdout propio medido con esos pesos nuevos.

Generación y verificación del archivo de entrega

Formato exigido:

```
id,trip_duration
id_00001,650.79453
id_00002,412.00000
...
```

Los números anteriores son **ilustrativos del formato**, no filas copiadas de la entrega.

Comprobaciones programadas:

- **100,000** registros.
- Columnas exactas y en orden.
- Cada `id` aparece una sola vez.
- Mismo orden que `test.csv`.
- Segundos numéricos, finitos y ≥ 0.

¿Por qué se hizo así?

No basta con entrenar bien: un CSV con IDs omitidos, columnas de más o valores negativos sería una entrega incorrecta.

Conclusiones principales

1. El problema es **regresión**, por lo que el objetivo correcto es **minimizar RMSLE**.
2. La auditoría detectó duraciones extremas y coordenadas GPS incoherentes.
3. La creación de **81 variables** permite traducir contexto temporal y geográfico a números.
4. **Ridge se escaló**; los modelos de árbol **no necesitaron escalado**.
5. LightGBM profundo ganó entre los candidatos: **0.375735 en validación** y **0.381219 en holdout**.
6. El archivo `submission.csv` tiene las 100,000 predicciones requeridas.

Limitaciones y trabajo futuro

- No conocemos la duración real del **test ciego**: no podemos asegurar su RMSLE.
- El **RMSLE de holdout** es una estimación, no una garantía de puntaje.
- El umbral de **12 horas** es una decisión a contrastar con otras estrategias.
- No se dispone aquí de tráfico real, accidentes, clima o rutas de calles.
- Podrían probarse **validación temporal**, optimización más amplia de hiperparámetros y variables de tránsito; habría que volver a evaluar sin fuga.

¿Por qué se hizo así?

"Mejor modelo" significa **el mejor entre los ensayados**, no una demostración de óptimo global.

Preguntas que pueden hacer en clase

1. **¿Por qué no F1 o accuracy?** Porque se predicen segundos continuos.
2. **¿Por qué el logaritmo?** Por cola larga y por coherencia con RMSLE.
3. **¿Por qué no escalaste LightGBM?** Porque las particiones por umbrales no dependen de esa escala.
4. **¿Por qué filtrar > 12 h solo en train?** Para limitar ruido sin ocultarlo en evaluación.
5. **¿Por qué LightGBM y no XGBoost?** Tuvo menor RMSLE de validación en estos experimentos.
6. **¿Conoces el puntaje de test?** No; carece de etiquetas de duración.

Fuentes y archivos para reproducir

- *U5 - 01 - ML.pdf*: aprendizaje supervisado; regresión vs. clasificación (p. 7).
- *U5 - 02 - Perceptrón.pdf*: regresión lineal, función de costo, descenso de gradiente (pp. 3–7).
- *03 - Ciclo de vida del ML.pdf*: CRISP-DM, calidad, partición, fuga, imputación, escalado y métricas (pp. 2–5, 8–15, 19–24).
- `Prediccion_Taxis_NYC_Paso_a_Paso.ipynb`: ejecución y decisiones exactas.
- `resultados/metricas.json`, `comparacion_modelos.csv` y gráficas: evidencia experimental.

¡Gracias!