# Ciclo de Vida del Machine Learning

## Feature Engineering y Evaluación de Modelos

### Licenciatura en Matemáticas Aplicadas y Computación

Facultad de Estudios Superiores Acatlán
Universidad Nacional Autónoma de México



# ¿Qué es el ciclo de vida del Machine Learning?

**Definición**

Conjunto de **etapas iterativas** que van desde **entender el problema** hasta **poner el modelo en producción** y **monitorearlo**: no es entrenar una vez, sino un **proceso continuo** que vuelve a empezar cuando los datos o el contexto cambian.

## Características

- **Iterativo:** se regresa a etapas previas.
- **Centrado en datos:** el 70–80 % del esfuerzo está en los datos.
- **Centrado en el problema:** la métrica nace del objetivo.

## Malentendido común

Creer que el ML es solo **el algoritmo**. En realidad el algoritmo es una pieza: la calidad de los **datos** y la **evaluación** pesan mucho más en el resultado final.

# El ciclo de vida: las etapas



# CRISP-DM: el estándar de la industria

## CRISP-DM

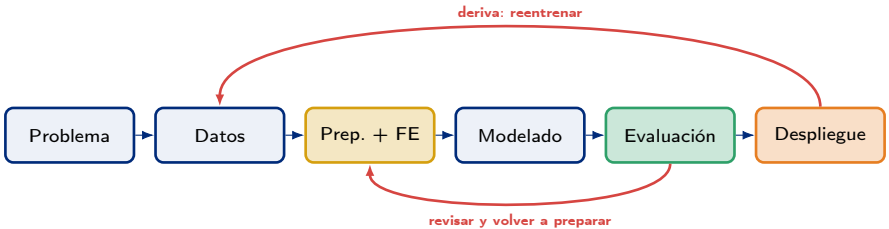
*Cross-Industry Standard Process for Data Mining*: metodología de referencia que organiza un proyecto de datos en **seis fases** relacionadas de forma cíclica.

- Nació en 1996; sigue siendo el marco más usado por analistas.

| Fase | Pregunta guía |
|---|---|
| Negocio | ¿Qué problema resolvemos y cómo se mide? |
| Datos | ¿Qué tenemos y qué calidad tiene? |
| Preparación | ¿Cómo lo dejamos listo para modelar? |
| Modelado | ¿Qué técnica se ajusta mejor? |
| Evaluación | ¿Cumple el objetivo del negocio? |
| Despliegue | ¿Cómo llega al usuario final? |

## No es un proceso lineal

Rara vez avanzamos en secuencia. Descubrir faltantes nos obliga a recolectar más datos; una evaluación pobre nos regresa al feature engineering; el monitoreo detecta, deriva y dispara un reentrenamiento.




El **feature engineering** es el punto al que más se regresa: mejorar las variables suele dar más que cambiar de algoritmo.

# Caso de estudio: el dataset Titanic

## El problema

Predecir, para cada pasajero, si **sobrevivió** al hundimiento del RMS Titanic (1912). Es un problema de **clasificación binaria**.

- $n = 891$ pasajeros (conjunto de entrenamiento).
- **Target:** `Survived` $\in \{0, 1\}$.
- Clases desbalanceadas: $\approx 38\,\%$ sobrevivió.

## Variables originales

| | |
|---|---|
| `Pclass` | clase del boleto (1,2,3) |
| `Name` | nombre y título |
| `Sex` | sexo |
| `Age` | edad (años) |
| `SibSp` | hermanos/cónyuge a bordo |
| `Parch` | padres/hijos a bordo |
| `Ticket` | número de boleto |
| `Fare` | tarifa pagada |
| `Cabin` | camarote |
| `Embarked` | puerto (C,Q,S) |

## Tipos de variables

| Tipo | Definición | Ejemplos en Titanic |
|---|---|---|
| Numérica continua | Acepta cualquier valor en un rango. | `Age`, `Fare` |
| Numérica discreta | Enteros con conteo. | `SibSp`, `Parch`, `Pclass` |
| Categórica nominal | Sin orden natural. | `Sex`, `Embarked` |
| Categórica ordinal | Con orden. | `Pclass` ($1^{\underline{a}} > 2^{\underline{a}} > 3^{\underline{a}}$) |
| Texto | Cadena libre. | `Name`, `Ticket`, `Cabin` |
| Binaria | Dos estados. | `Survived` (target) |

### ¿Por qué importa?

El **tipo** de cada variable decide qué tratamiento necesita: las categóricas se codifican, las numéricas se escalan y el texto se convierte en variables útiles.

## Calidad de los datos

"Garbage in, garbage out": un modelo excelente sobre datos sucios produce predicciones inútiles. La auditoría es un paso obligatorio.

### Problemas típicos

- **Faltantes**
- **Duplicados**
- **Valores atípicos**
- **Inconsistencias** `Age` negativa o `Fare`$= 0$.

### Desbalance de clases




Con clases desbalanceadas, la exactitud (*accuracy*) puede engañar; lo veremos en la evaluación.

## Partición de los datos

E
l modelo debe evaluarse sobre datos que **nunca vio**. Reservamos una parte de los datos para ello.




**Entrenamiento:** el modelo ajusta sus parámetros.

**Validación:** elige modelo e hiperparámetros.

**Prueba:** estima el desempeño **final**, una sola vez.

### Detalle importante

Con clases desbalanceadas se usa una partición **estratificada**, que conserva la proporción 62/38 en cada subconjunto.

# Fuga de información (*data leakage*)

**Definición**

Ocurre cuando el modelo usa, durante el entrenamiento, información que **no estará disponible** al predecir en el mundo real. Produce métricas **optimistas** y modelos que fallan en producción.

## Ejemplos en Titanic

- Imputar `Age` con la **media de todo** el dataset *antes* de partir (la media "ve" el conjunto de prueba).
- Escalar con la media y desviación de **test**.
- Seleccionar variables usando **test**.
- Filtrar duplicados entre train y test.

## Regla práctica

`fit` **solo en entrenamiento**
`transform` **en validación y prueba**

Toda la preparación (imputación, codificación, escalado) debe ocurrir **dentro** de un `Pipeline` ajustado únicamente con train.

## ¿Qué es el Feature Engineering?

### Definición

Es el proceso de **transformar datos crudos** en variables (*features*) que **representen mejor** el problema, de modo que el modelo pueda aprender con más facilidad y precisión.

### Idea central

El modelo solo "ve" los números que le damos. Si esos números no capturan la señal, ningún algoritmo lo arregla.

### Analista vs. modelo

El **conocimiento del dominio** (por qué un pasajero importante sobrevivió) se codifica en las variables.

## Panorama de técnicas




**Imputación:** rellenar faltantes con un criterio razonable.

**Codificación:** convertir categorías en números.

**Escalado:** poner las variables en rangos comparables.

**Creación:** construir variables nuevas con el dominio.

**Selección:** descartar las variables poco útiles.

## Imputación de valores faltantes

- **Eliminar filas:** solo si faltan pocos casos; perder datos cuesta.
- **Media / mediana** (numéricas): la mediana es robusta a atípicos. `Age` → mediana por `Pclass`.
- **Moda** (categóricas): `Embarked` → puerto más frecuente.
- **Indicador de faltante:** una columna `Age_missing` puede ser informativa por sí misma.
- **KNN / iterativo:** estima con vecinos o con otros modelos.

### En Titanic

| Variable | Faltantes | Estrategia |
|---|---|---|
| `Age` | 177 | mediana por clase |
| `Cabin` | 687 | `HasCabin` (0/1) |
| `Embarked` | 2 | moda |
| `Fare` | 0 | — |

**Recuerda**

Imputar **después** de partir los datos y calcular los valores (medianas, modas) **solo con train**.

# Codificación de variables categóricas

## One-Hot Encoding

Una columna binaria por categoría. Ideal para variables **nominales** (`Embarked`, `Sex`).

| Original | | One-Hot | | |
|---|---|---|---|---|
| `Sex` | `Embarked` | S | C | Q |
| male | S | 0 | 0 | 1 |
| female | C | 1 | 1 | 0 |

## Otras codificaciones

- **Ordinal:** mantiene el orden. `Pclass`→1,2,3.
- **Label:** entero arbitrario; solo para modelos de árbol o como paso intermedio.

### Cuidado con la dimensionalidad

El one-hot puede explotar con categorías de alta cardinalidad.

## Escalado de variables numéricas

### Tres métodos

Estandarización: $z = \dfrac{x - \mu}{\sigma}$ (media 0, $\sigma = 1$)

Min–max: $x' = \dfrac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}} \in [0, 1]$

Robusto: $x' = \dfrac{x - \text{mediana}}{\text{IQR}}$

- Necesario para modelos **sensibles a la escala**: regresión con regularización, KNN, SVM, redes neuronales.
- **No** necesario para árboles y bosques: dividen por umbrales.
- $\mu$, $\sigma$, min, max se calculan **solo con train**.

## Creación de variables: la parte creativa

**Del dominio al dato:** combinamos o descomponemos columnas para exponer la señal que el modelo no ve directamente.

| Variable nueva | Cómo se construye | Intuición |
|---|---|---|
| `Title` | extraer el título de `Name` (Mr, Mrs, Miss...) | Resume sexo, edad y estatus. |
| `FamilySize` | `SibSp` + `Parch` + 1 | Tamaño del grupo familiar a bordo. |
| `IsAlone` | `FamilySize` = 1 | Viajar solo cambia la supervivencia. |
| `Deck` | primera letra de `Cabin` (A–G) | Cercanía a los botes salvavidas. |
| `HasCabin` | `Cabin` no es nulo | Indica mejor clase. |
| `FareBand` | discretizar `Fare` en cuantiles | Efecto no lineal del precio. |

## Ejemplo: de la variable cruda a la útil

### Antes (crudo)

| Name | Age |
|---|---|
| Braund, **Mr.** Owen | 22 |
| Cumings, **Mrs.** John | 38 |
| Heikkinen, **Miss.** Laina | 26 |
| ... | ... |

### Después (features)

| Title | Age | Fam. | Alone |
|---|---|---|---|
| Mr | 22 | 2 | 0 |
| Mrs | 38 | 2 | 0 |
| Miss | 26 | 1 | 1 |
| ... | ... | ... | ... |

### Efecto

`Title` concentra información de sexo, edad y clase en una sola variable: el modelo aprende mejor con menos ruido.

## Selección de variables

Feature engineering $\neq$ selección

La **creación** produce variables nuevas; la **selección** decide **cuáles conservar** para reducir ruido, dimensionalidad y tiempo.

### Filter

Criterio estadístico independiente del modelo: **correlación**, información mutua, $\chi^2$.

### Wrapper

Evalúa subconjuntos entrenando el modelo: **RFE**, selección hacia adelante.

### Embedded

La propia regularización selecciona: **Lasso**, **importancia** en árboles.

# ¿Qué significa evaluar?

## Objetivo

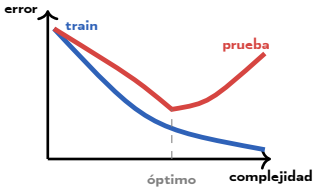
Estimar el **desempeño de generalización**: qué tan bien predice el modelo sobre datos **nuevos**, no sobre los que ya memorizó.

### Overfitting (sobreajuste)

Excelente en train, pobre en prueba: el modelo "memorizó" el ruido.

### Underfitting (subajuste)

Pobre en train y en prueba: el modelo es demasiado simple para la señal.



## Métricas de regresión

| Métrica | Qué mide |
|---|---|
| MAE | Error absoluto medio: magnitud del error en las unidades del target. |
| MSE | Error cuadrático medio: penaliza más los errores grandes. |
| RMSE | Raíz del MSE: vuelve a las unidades del target. |
| $R^2$ | Fracción de la varianza del target explicada por el modelo. |

## La trampa de la exactitud

### Un modelo inútil con 62 % de acierto

En Titanic, $\approx 62\,\%$ de los pasajeros **no** sobrevivió. Un modelo que **siempre** predice "no sobrevive" acierta el 62 % de las veces ... pero es **completamente inútil**: nunca detecta un sobreviviente.

**Exactitud (*accuracy*)**

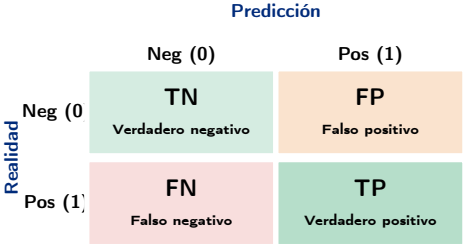
$$\text{Accuracy} = \frac{\text{aciertos}}{\text{total}} = \frac{TP + TN}{TP + TN + FP + FN}$$

- Falla con **clases desbalanceadas**.
- Necesitamos métricas que distingan **cada tipo de error**.
- La herramienta central es la **matriz de confusión**.

# Matriz de confusión

## Definición

Tabla que cruza la **clase real** con la **clase predicha**. Resume los cuatro tipos de resultado posibles de un clasificador binario.




- **TP:** predijo positivo y era positivo.
- **TN:** predijo negativo y era negativo.
- **FP:** predijo positivo y era negativo (falsa alarma).
- **FN:** predijo negativo y era positivo (error que se escapa).

## Las cuatro celdas, en el contexto de Titanic

| Celda | Significado | En Titanic |
|---|---|---|
| **TP** | Real positivo, predicho positivo | Sobrevivió y lo anticipamos. |
| **TN** | Real negativo, predicho negativo | No sobrevivió y lo anticipamos. |
| **FP** | Real negativo, predicho positivo | Dijimos que sobrevivía y no. |
| **FN** | Real positivo, predicho negativo | Sobrevivió y no lo detectamos. |

### ¿Qué error duele más?

Depende del objetivo. En un diagnóstico médico, **FN** (no detectar al enfermo) puede ser mucho más grave que **FP**. La elección de métrica refleja prioridades del problema.

## Métricas derivadas de la matriz

### Precision (precisión)

$$\text{Precision} = \frac{TP}{TP + FP}$$

De los que marqué positivos, ¿cuántos lo eran? Alta precisión $\Rightarrow$ pocas **falsas alarmas**.

### Recall / sensibilidad

$$\text{Recall} = \frac{TP}{TP + FN}$$

De los positivos reales, ¿cuántos detecté? Alto recall $\Rightarrow$ pocos **positivos perdidos**.

### F1 (media armónica)

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Equilibra precisión y recall en un solo número.

### Especificidad

$$\text{Especificidad} = \frac{TN}{TN + FP}$$

De los negativos reales, ¿cuántos reconocí como negativos?

# Curvas de aprendizaje: diagnosticar el desempeño

- Graficamos el error de **train** y **validación** contra el tamaño del conjunto de entrenamiento (o la complejidad).
- **Brecha grande** $\Rightarrow$ sobreajuste.
- **Ambas curvas altas** $\Rightarrow$ subajuste.
- Guía la decisión: más datos, más variables, regularización.

